

面向多源中文舆情的 上市公司风险研判方法研究

王岩方 李凯迪 彭绎陶 冉源潮

(综合设计实验)

摘 要

随着信息传播渠道的多元化，上市公司相关舆情呈现来源分散、文本非结构化、传播迅速、影响链条复杂等特征，给投资者与风控人员的及时研判带来挑战。现有研究中，基于情感词典的方法透明可解释但难以刻画语境语义，基于预训练语言模型的方法精度较高但对算力与服务稳定性依赖较强，且二者多聚焦于情绪度量本身，较少形成从异构文本到可解释风险结论、再到历史有效性验证的完整闭环。

针对上述问题，本文研究面向多源中文舆情的上市公司风险研判方法，并实现了一套可复现、可解释、可验证的端到端辅助决策系统。主要工作包括四个方面。第一，提出多源异构舆情的统一治理与时点对齐方法，将新闻、公告、股吧讨论与行情数据规整为统一文本事件表，并通过交易日锚定规则避免未来信息泄漏。第二，提出词典基线与领域预训练模型相融合、且在模型不可用时自动降级的情绪计算方案，在保证鲁棒性与可复现性的同时兼顾精度与可解释性。第三，设计基于多规则加权的可解释风险识别引擎，输出风险等级、触发规则与文本证据，使每一条风险结论均可回溯。第四，基于事件研究法构建风险信号的回测验证框架，并设计情绪方法对比、模块消融与参数敏感性等系统化实验。

在 121,768 条统一文本事件、1,000 只 A 股标的的数据集上的实验表明：所提融合情绪方案的情绪分类性能显著优于纯词典法，并接近单一模型法，同时以约 1.7 个百分点的精度代价换取了纯模型法所不具备的可解释性与模型不可用时的自动降级能力；消融实验验证了情绪、主题与背离规则模块对风险识别均有正向贡献；参数敏感性分析给出了融合系数与风险阈值的合理取值区间。所提方法能够稳定地产生可解释、可审计的舆情风险辅助信号，可为上市公司舆情风险的辅助研判提供系统化的方法与工程参考。

关键词：多源舆情；金融文本；情绪计算；风险预警；事件研究；可解释性

Research on Risk-Assessment Methods for Listed Companies Based on Multi-Source Chinese Public Opinion

Abstract

With the diversification of information channels, public opinion concerning listed companies exhibits dispersed sources, unstructured text, rapid propagation and complex impact chains, posing challenges to the timely judgment of investors and risk-control practitioners. In existing research, lexicon-based methods are transparent and explainable but struggle to capture contextual semantics, whereas pre-trained-language-model methods achieve higher accuracy yet rely heavily on computing power and service stability; moreover, both tend to focus on sentiment measurement itself and rarely form a complete loop from heterogeneous text to explainable risk conclusions and on to historical validation.

To address these issues, this paper studies risk-assessment methods for listed companies based on multi-source Chinese public opinion and implements a reproducible, explainable and verifiable end-to-end decision-support system. The main contributions are fourfold. First, a unified governance and temporal-alignment method is proposed, regularizing news, disclosures, stock-forum posts and market quotes into a unified text-event table, with a trading-day anchoring rule to prevent look-ahead bias. Second, a sentiment-computing scheme that fuses a lexicon baseline with a domain-pretrained model—and degrades automatically when the latter is unavailable—balances robustness, reproducibility, accuracy and explainability. Third, an explainable multi-rule risk-detection engine outputs risk levels, triggered rules and textual evidence, making every conclusion traceable. Fourth, an event-study-based backtesting framework is constructed, together with systematic experiments on sentiment-method comparison, module ablation and parameter sensitivity. Experiments on a dataset of 121,768 unified text events over 1,000 A-share stocks show that the proposed fused sentiment scheme significantly outperforms the pure-lexicon method and approaches the single-model method on sentiment classification, trading roughly 1.7 percentage points of accuracy for explainability and an automatic-degradation capability that the pure model lacks; ablation studies confirm the positive contribution of the sentiment, topic and divergence-rule modules to risk detection; and sensitivity analysis identifies reasonable ranges for the fusion coefficient and risk threshold. The proposed method stably produces explainable and auditable auxiliary risk signals, providing a systematic methodological and engineering reference for public-opinion risk assessment of listed companies.

Keywords: multi-source public opinion; financial text; sentiment computing; risk early-warning; event study; explainability

目 录

1 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	1
1.2.1 金融文本情绪分析	1
1.2.2 主题建模与关键词提取	2
1.2.3 事件研究与市场预测	2
1.3 存在的问题与本文工作	2
1.4 论文组织结构	3
2 相关理论基础	3
2.1 文本表示与 TF-IDF	3
2.2 情感分析方法	3
2.3 主题模型 LDA	4
2.4 事件研究方法	4
3 面向多源中文舆情的风险研判方法	4
3.1 方法总体框架	4
3.2 多源数据治理与时点对齐	5
3.2.1 统一文本事件模式	5
3.2.2 交易日锚定	5
3.3 融合情绪计算	6
3.3.1 词典法情绪得分	6
3.3.2 领域模型情绪得分与融合	6
3.4 多粒度主题提取	7
3.5 可解释的风险识别	7
3.5.1 风险规则设计	7
3.5.2 综合风险分数	8
3.6 基于事件研究的回测验证	8
4 系统设计与实现	9
4.1 总体架构	9
4.2 关键技术选型	9
4.3 数据持久层设计	10
4.4 服务接口设计	10

4.5 可视化展示	10
4.5.1 指挥总览页面	11
4.5.2 单股详情页面	11
4.5.3 舆情钻取页面	12
4.5.4 回测验证页面	12
5 实验与结果分析	13
5.1 实验设置	13
5.1.1 数据集	13
5.1.2 情绪标注评测子集	15
5.1.3 方向判别的特征与标签	15
5.1.4 评价指标	16
5.1.5 对比方法	16
5.2 情绪方法对比实验	16
5.3 风险识别消融实验	17
5.4 参数敏感性分析	18
5.4.1 融合系数 α	18
5.4.2 风险阈值 θ	19
5.5 综合结果与讨论	19
6 讨论	21
6.1 方法有效性分析	21
6.2 局限性分析	21
6.3 改进方向	22
7 结论与展望	22
7.1 全文总结	22
7.2 研究展望	23
参考文献	23

图目录

图 1 风险研判方法总体框架	5
图 2 系统六层总体架构	9
图 3 指挥总览页面（核心区）。顶部为全局指标卡（监测标的数、样本总数、活跃预警、谣言事件），左侧为焦点个股价格—情绪—热度三线联动图，右侧为按热度与风险排序的实时舆情热度榜 Top 10；页面下方另设数据链路说明与风险事件快线（因版面所限未全部截取）	11
图 4 单股因子详情页面（核心区）。以个股最新价格、情绪结论、舆情热度与疑似谣言占比为核心指标，并以数据接入与算法结果汇总卡片展示覆盖规模、回测触发与风险评分；下方进一步给出单股联动图、代表性舆情摘要（文本证据）、来源覆盖与风控占比以及 AI 研判简报	12
图 5 舆情钻取页面（核心区）。在指定预警日期下将当日新闻热度拆解为核心新闻流，逐条标注情绪倾向与置信度；右侧给出负面占比、总信号数、关键负面驱动词、重点观察主题与数据覆盖情报，实现从聚合风险信号到具体文本证据的逐层下钻	13
图 6 回测验证页面（以 600519.SH 单股示例）。核心指标为历史触发次数、平均前向收益、最大回撤与负收益命中率；下方“平均收益轨迹”展示触发后 1~10 日走势，“收益分布”展示触发后收益的离散程度。单股口径下的指标与表 8 的全样本聚合结果不同	14
图 7 多源文本数据来源构成	15
图 8 三种情绪方法在各类别上的 F1 分解	17
图 9 本文融合法的归一化混淆矩阵（评测子集）	18
图 10 融合系数 α 对情绪分类性能的影响	19
图 11 不同阈值下风险等级分布	20
图 12 风险信号触发后平均前向收益轨迹（阴影为 95% 置信区间）	21

表目录

表 1 风险识别规则、触发判据与权重	8
表 2 各层关键技术选型	10
表 3 主要服务接口	10
表 4 多源数据构成	14
表 5 情绪方法对比结果	17
表 6 风险识别消融实验	18
表 7 风险阈值 θ 的敏感性	19
表 8 方法综合结果（默认配置）	20

主要符号说明

符号	含义
$\mathcal{D} = \{d_1, \dots, d_N\}$	多源中文文本事件集合, N 为事件总数
c, t	股票代码与交易日
τ_i	第 i 条文本的原始时间戳
$A(\tau)$	时间戳 τ 对应的可生效交易日 (锚定函数)
$s_{\text{lex}}(d)$	文本 d 的词典法情绪得分
$s_{\text{model}}(d)$	文本 d 的领域模型情绪得分
$s(d)$	文本 d 的融合情绪得分
α	情绪融合系数, $\alpha \in [0, 1]$
$\text{pol}(w), \mu(w), \nu(w)$	词 w 的情感极性、程度权重与否定修正
$\text{tfidf}(w, d)$	词 w 在文本 d 中的 TF-IDF 权重
$WS(v_i)$	节点 v_i 的 TextRank 重要性得分
$r_{c,t} \in [0, 100]$	股票 c 在交易日 t 的综合风险分数
ω_j	第 j 条风险规则的权重
θ	风险预警阈值
$R_i^{(h)}$	标的 i 在事件后第 h 日的前向收益
MDD_i	标的 i 在事件窗口内的最大回撤

1 绪论

1.1 研究背景与意义

近年来，随着移动互联网与社交媒体的快速普及，与上市公司相关的信息在新闻门户、监管披露平台、投资者社区等多种渠道上高速生成与传播。这些信息共同构成了所谓“舆情”，深刻影响着投资者预期与资产价格。与传统的结构化财务数据不同，舆情数据具有四个突出特征：来源高度分散，新闻、公告、论坛讨论与行情分属不同平台且格式各异；文本高度非结构化，难以直接用于定量分析；传播迅速，热点事件可在数小时内大范围扩散；影响链条复杂，单一事件可能经由情绪传染、关注度上升、交易行为变化等多重机制作用于价格。

在此背景下，如何从海量、异构、噪声较高的多源文本中及时、准确地识别出潜在风险，成为投资者保护与市场稳定的重要课题，也是金融科技领域的研究热点。从实践角度看，一套能够自动汇聚多源舆情、量化市场情绪、提示潜在风险并给出可解释依据的系统，能够显著降低风控人员的信息处理负担；从研究角度看，将自然语言处理、文本挖掘与金融计量方法相结合，对中文金融文本这一特定语料开展系统化建模与验证，具有方法论上的探索价值。本文的研究意义正在于：在课程项目可控的资源约束下，探索一条从多源异构文本到可解释、可回溯、可验证风险信号的完整技术路线，为相关方法研究与工程实现提供参考。

1.2 国内外研究现状

1.2.1 金融文本情绪分析

金融文本情绪分析是本文方法的基础，其发展大体经历了从词典法、传统机器学习到深度学习的演进 [2]。在词典法方面，早期研究多借用通用领域情感词典，但 Loughran 与 McDonald 指出通用词典在金融语境下存在严重误判，并据此构建了更契合金融文本的专用词表，将其与公司披露的收益、成交量与波动率等指标相关联 [3]；其后续综述进一步系统梳理了文本分析在会计与金融中的应用脉络 [4]。针对中文金融文本，姜富伟等在 Loughran-McDonald 词典基础上，结合 word2vec 算法与人工筛选构建了中文金融情感词典，并发现由此提取的媒体文本情绪对我国股票回报具有显著的样本内与样本外预测能力 [1]，为中文金融情绪研究奠定了重要基础。词典法的共同优势在于透明、可解释、无需大规模标注，但其固有局限在于难以建模上下文、语序与领域特定语义。

随着预训练语言模型的兴起，基于 BERT[5] 的方法显著提升了文本语义理解能

力。Araci 提出的 FinBERT 通过在金融语料上继续预训练，在金融情感分类任务上取得了优于传统机器学习方法的表现，且在标注样本有限时仍具优势 [6]。此类方法精度更高，但对算力、标注与模型服务稳定性的依赖也更强，在资源受限或要求高可复现性的场景中部署成本较高。综合来看，词典法与模型法各有优劣，如何在二者之间取得平衡，是面向实际工程的关键问题之一。本文据此提出“词典基线 + 领域模型可选通道 + 自动降级”的融合策略。

1.2.2 主题建模与关键词提取

为刻画舆情“讨论什么”，主题建模与关键词提取被广泛使用。Blei 等提出的潜在狄利克雷分配 (LDA) 将文档建模为潜在主题的混合、主题建模为词上的概率分布，是文本主题分析的经典生成模型 [7]。在关键词层面，Mihalcea 与 Tarau 提出的 TextRank 将词视为图节点、依共现关系构图并以类 PageRank 方式排序，从而无监督地抽取关键词与摘要 [8]。近年来，结合预训练嵌入的主题建模方法（如 BERTopic）在动态主题分析中也得到应用 [2]。本文综合 TF-IDF、TextRank 与 LDA，从词频区分度、图中心性与主题簇三个互补角度进行多粒度主题提取，以增强结果稳健性。

1.2.3 事件研究与市场预测

事件研究法为度量信息冲击对证券价格的影响提供了成熟范式。MacKinlay 系统总结了其方法论：在市场有效假设下，事件影响会迅速反映到价格中，因而可通过考察事件前后窗口的收益度量其冲击 [9]。在情绪与市场预测的结合上，研究表明媒体情绪等文本情绪指标对股票回报具有预测能力 [1]；Jiang 等进一步构建了管理者情绪指标，发现其对企业未来收益与投资具有显著的预测作用，从更微观的主体视角印证了文本情绪的市场价值 [11]。在预测模型方面，梯度提升树因其在结构化特征上的优良表现而被广泛采用，Chen 与 Guestrin 提出的 XGBoost 是一种可扩展的树提升系统 [10]。本文借鉴事件研究范式构建风险信号的回测框架，并以 XGBoost 建立方向辅助判别模型，但仅将其作为风险提示而非交易策略。

1.3 存在的问题与本文工作

综合现有研究可以发现，尽管金融文本情绪分析、主题建模与事件研究等单项技术已较为成熟，但在面向上市公司舆情风控的实际场景中仍存在三方面不足：其一，多数研究聚焦于情绪度量本身，较少形成“多源治理 → 情绪/主题分析 → 可解释风险识别 → 历史验证”的完整闭环；其二，方法的可解释性与可复现性常被忽视，

而这恰是风控场景人工复核所必需；其三，对信息时点对齐等容易引入未来信息泄漏的细节关注不足。

针对上述问题，本文的主要工作如下：

- (1) 提出多源异构舆情的统一治理与交易日锚定方法，为后续分析与回测提供一致且无未来信息泄漏的数据基础；
- (2) 提出可自动降级的融合情绪计算方案，并通过对比实验验证其相对纯词典法与单一模型法的优势；
- (3) 设计可解释的多规则风险识别引擎，并通过消融实验量化各模块贡献；
- (4) 构建基于事件研究的回测框架，并辅以参数敏感性分析，系统评估方法的有效性与边界；
- (5) 实现完整的端到端系统，验证方法在真实规模数据上的可行性与工程价值。

1.4 论文组织结构

本文共分七章。第1章为绪论，介绍研究背景、意义、国内外研究现状与本文工作。第2章阐述相关理论基础。第3章提出面向多源中文舆情的风险研判方法，是本文的核心。第4章介绍系统的总体设计与实现。第5章给出实验设计与结果分析，包括情绪方法对比、消融实验与参数敏感性分析。第6章对方法的有效性、局限与改进方向进行讨论。第7章总结全文并展望未来工作。

2 相关理论基础

2.1 文本表示与 TF-IDF

文本分析的首要步骤是将非结构化文本转化为可计算的表示。词袋模型将文档表示为词频向量，简单有效但忽略词序。为衡量词对文档的区分能力，TF-IDF 在词频基础上引入逆文档频率加权：高频出现在单一文档、却罕见于整个语料的词被赋予更高权重。TF-IDF 是关键词提取与文本相似度计算的常用基础，本文将其作为主题提取的组成部分之一。

2.2 情感分析方法

情感分析旨在判断文本的情感极性或强度。词典法依据预先构建的情感词表，对文本中的情感词进行极性累加，并辅以程度副词与否定词修正，其结果完全由词

表与规则决定，因而透明可解释。机器学习法将情感分析视为分类问题，依赖标注数据训练分类器。深度学习法，尤其是以 BERT[5] 为代表的预训练语言模型，通过在大规模语料上学习上下文表示，再在下游任务上微调，能够更好地建模语境语义；FinBERT[6] 即为其在金融领域的代表。本文融合词典法与模型法之长，详见第 3 章。

2.3 主题模型 LDA

潜在狄利克雷分配 (LDA) 是一种三层贝叶斯生成模型 [7]。其基本假设是：每篇文档由若干潜在主题以一定比例混合而成，每个主题则表现为词表上的一个概率分布。给定语料，LDA 通过贝叶斯推断估计文档—主题分布与主题—词分布，从而无监督地发现语料中的主题结构。本文以 LDA 提供高层次的主题归纳，与 TF-IDF、TextRank 形成多粒度互补。

2.4 事件研究方法

事件研究法用于度量特定事件对资产价格的影响 [9]。其核心思想是：选定事件日作为锚点，定义事件窗口，并在窗口内考察资产收益相对于正常收益的偏离。本文借鉴这一思想，以风险信号触发日为事件锚点，统计其后若干交易日的前向收益与最大回撤，从而对风险信号的历史有效性进行可审计的量化评估。需要说明的是，受数据条件限制，本文采用简化的事件研究框架，以原始前向收益近似刻画事件后的价格走势，未引入市场模型对正常收益进行调整。

3 面向多源中文舆情的风险研判方法

3.1 方法总体框架

本文方法旨在将多源异构的中文舆情文本转化为可解释、可回溯的风险信号，并对其历史有效性进行验证。给定文本事件集合，方法的整体目标可形式化描述如下。

定义 3.1 (舆情风险研判问题) 设多源中文文本事件集合为 $\mathcal{D} = \{d_1, d_2, \dots, d_N\}$ ，每条事件 d_i 关联股票代码 c_i 、原始时间戳 τ_i 与来源 src_i 。舆情风险研判问题是指：构造映射 Φ ，使得对任意股票 c 与交易日 t ，输出风险分数 $r_{c,t} = \Phi(\mathcal{D}_{c,t}) \in [0, 100]$ 及其可解释依据，其中 $\mathcal{D}_{c,t}$ 为锚定到 (c, t) 的事件子集；并通过事件研究评估 $r_{c,t}$ 对后续价格走势的指示能力。

方法由数据治理与时点对齐、情绪计算、多粒度主题提取、可解释风险识别与

回测验证五个环节构成，其总体框架如图 1 所示。




图 1 风险研判方法总体框架

3.2 多源数据治理与时点对齐

3.2.1 统一文本事件模式

不同来源的原始字段差异较大。为使下游方法仅依赖一致字段，本文将异构数据统一映射到标准事件模式：

```
id, timestamp, stock_code, stock_name, text_content,
source, event_type, read_count, comment_count, text_length, url
```

清洗流程包括空文本与极短文本过滤、按唯一键与文本内容去重、时间戳规范化、来源枚举校验，以及股票代码与名称对齐。

3.2.2 交易日锚定

舆情文本在全天连续产生，而价格仅在交易时段变动。若直接以文本自然日参与风险计算与回测，可能将收盘后乃至非交易日产生的信息错误地归入当日，造成未来信息泄漏。为此，本文定义交易日锚定函数。

定义 3.2 (交易日锚定) 设 τ 为文本时间戳， $\mathcal{T}$ 为交易日集合，则锚定交易日 $A(\tau)$ 定义为

$$A(\tau) = \begin{cases} \text{date}(\tau), & \text{date}(\tau) \in \mathcal{T} \text{ 且 } \tau \leq t_{\text{close}}, \\ \min\{t \in \mathcal{T} \mid t > \text{date}(\tau)\}, & \text{其他情形,} \end{cases} \quad (1)$$

其中 t_{close} 为当日收盘时刻。

性质 3.1 由式 (1) 可知, 对任意交易日 t , 锚定到 t 的事件子集 $\mathcal{D}_{c,t}$ 仅包含在 t 日收盘前可观测的信息, 从而保证风险计算与回测不引入未来信息。

3.3 融合情绪计算

情绪计算是风险识别的关键输入。本文提出词典法与领域模型相融合、且支持自动降级的情绪计算方案, 兼顾精度、可解释性与鲁棒性。

3.3.1 词典法情绪得分

词典法依据情感词、程度副词与否定词计算文本极性。对文本 d , 其词典法情绪得分定义为

$$s_{\text{lex}}(d) = \frac{\sum_{w \in d} \text{pol}(w) \mu(w) \nu(w)}{\max(1, |W^{\pm}(d)|)}, \quad (2)$$

其中 $\text{pol}(w) \in \{-1, +1\}$ 为情感极性, $\mu(w) \geq 1$ 为程度副词权重, $\nu(w) \in \{-1, +1\}$ 为否定修正系数, $W^{\pm}(d)$ 为文本中的情感词集合。本文情感词表在通用中文情感词典基础上, 融入面向金融领域的词表 [1], 以提升领域适配性。

3.3.2 领域模型情绪得分与融合

当领域预训练模型 (如 FinBERT[6]) 可用时, 以其三分类概率映射连续情绪:

$$s_{\text{model}}(d) = p^{+}(d) - p^{-}(d), \quad (3)$$

其中 $p^{+}(d), p^{-}(d)$ 分别为正、负面概率。最终情绪得分按可用性融合并支持自动降级:

$$s(d) = \begin{cases} \alpha s_{\text{model}}(d) + (1 - \alpha) s_{\text{lex}}(d), & \text{模型可用,} \\ s_{\text{lex}}(d), & \text{模型不可用 (降级),} \end{cases} \quad (4)$$

其中 $\alpha \in [0, 1]$ 为融合系数, 用于权衡模型精度与词典可解释性。融合情绪计算的完整流程如算法 1 所示。

算法 1 融合情绪计算（支持自动降级）

输入： 文本事件集合 $\mathcal{D}$ ，情感词表 L ，融合系数 α ，模型可用标志 *avail*

输出： 各文本的融合情绪得分 $\{s(d)\}$

```

1: 对于 每条文本  $d \in \mathcal{D}$  执行
2:   分词并匹配情感词，依式 (2) 计算  $s_{\text{lex}}(d)$ 
3:   如果 avail 则
4:     以模型推断概率  $p^+(d), p^-(d)$ ，依式 (3) 计算  $s_{\text{model}}(d)$ 
5:      $s(d) \leftarrow \alpha s_{\text{model}}(d) + (1 - \alpha) s_{\text{lex}}(d)$ 
6:     记录得分来源为 fused
7:   否则
8:      $s(d) \leftarrow s_{\text{lex}}(d)$  ▷ 模型不可用时自动降级
9:     记录得分来源为 lexicon
10: 返回  $\{s(d)\}$ 
    
```

3.4 多粒度主题提取

为刻画舆情讨论焦点，本文从三个互补角度提取主题。其一，以 TF-IDF 度量词区分度：

$$\text{tfidf}(w, d) = \text{tf}(w, d) \cdot \log \frac{N}{1 + \text{df}(w)}, \quad (5)$$

其中 $\text{tf}(w, d)$ 为词频， $\text{df}(w)$ 为包含 w 的文档数。其二，以 TextRank[8] 在词共现图上迭代计算节点重要性：

$$WS(v_i) = (1 - \gamma) + \gamma \sum_{v_j \in \text{In}(v_i)} \frac{w_{ji}}{\sum_{v_k \in \text{Out}(v_j)} w_{jk}} WS(v_j), \quad (6)$$

其中 γ 为阻尼系数。其三，以 LDA[7] 给出主题簇层面的归纳。三者结合可从词频区分度、图中心性与主题分布三个层面提升结果稳健性与可读性。

3.5 可解释的风险识别

3.5.1 风险规则设计

本文设计基于规则的风险识别引擎，主要规则、其触发判据与权重如表 1 所示。每条规则均对应明确的、可量化的可观测条件，从而保证结果可解释、可复现。其中“显著高于历史基线”统一以滚动窗口（默认 20 个交易日）内的均值 $\bar{x}$ 与标准差 σ 定义的 z -分数刻画，即 $z = (x - \bar{x})/\sigma$ ；权重 ω_j 依据各规则在风控实践中的相对重要性人工设定，并经小样本回测微调，负面情绪与谣言类规则赋予较高权重，热度与成交量类规则作为辅助证据赋予较低权重。

表 1 风险识别规则、触发判据与权重

规则	触发语义	量化判据 ^a	权重 ω_j
负面情绪激增	个股日度负面情绪显著高于其历史基线	$z_{\text{neg}} > 2.0$	35
疑似谣言扩散	文本命中谣言关键词且传播度较高	命中且 $z_{\text{read}} > 1.5$	30
情绪—价格背离	情绪与价格走势方向相反，提示预期分歧	$\text{sign}(\Delta s) \neq \text{sign}(\Delta P)$	20
新闻热度异常	个股相关文本量在短期内异常放大	$z_{\text{vol}} > 2.0$	10
成交量异常	成交量显著偏离其近期正常水平	$z_{\text{turn}} > 2.0$	10

^a z -分数基于默认 20 交易日滚动窗口计算； Δs 、 ΔP 分别为情绪与价格的窗口变化量。各权重之和上限经式 (7) 截断至百分制。

3.5.2 综合风险分数

设规则集为 $\{\text{rule}_j\}_{j=1}^M$ ，规则 j 的权重为 ω_j ，则股票 c 在交易日 t 的综合风险分数定义为各触发规则权重的累加并截断至百分制：

$$r_{c,t} = \min\left(100, \sum_{j=1}^M \omega_j \cdot \mathbb{I}[\text{rule}_j \text{ 在 } (c,t) \text{ 触发}]\right). \quad (7)$$

进一步，依据阈值 θ 将风险分数离散为风险等级。风险识别的完整流程如算法 2 所示，引擎同时输出风险等级、触发规则列表与代表性文本证据，使每一条结论均可回溯。

算法 2 可解释风险识别

输入： 锚定事件集合 $\mathcal{D}_{c,t}$ ，情绪得分 $\{s(d)\}$ ，行情序列 P ，规则权重 $\{\omega_j\}$ ，阈值 θ
输出： 风险分数 $r_{c,t}$ 、风险等级与证据集合 E

- 1: 初始化 $r_{c,t} \leftarrow 0$, $E \leftarrow \emptyset$
- 2: **对于** 每条规则 rule_j **执行**
- 3: **如果** rule_j 在 (c,t) 上触发 **则**
- 4: $r_{c,t} \leftarrow r_{c,t} + \omega_j$
- 5: 将 rule_j 及其命中文本加入证据集合 E
- 6: $r_{c,t} \leftarrow \min(100, r_{c,t})$
- 7: 依阈值 θ 由 $r_{c,t}$ 确定风险等级
- 8: **返回** $r_{c,t}$ 、风险等级、证据集合 E

3.6 基于事件研究的回测验证

为客观评估风险信号的有效性，本文以风险信号触发日 t_0 为事件锚点，统计标的 i 在未来 h 个交易日的前向收益：

$$R_i^{(h)} = \frac{P_{i,t_0+h}}{P_{i,t_0}} - 1, \quad (8)$$

并在事件窗口 $[0, H]$ 内统计最大回撤：

$$\text{MDD}_i = \min_{0 \leq h \leq H} \left(\frac{P_{i,t_0+h}}{\max_{0 \leq k \leq h} P_{i,t_0+k}} - 1 \right). \quad (9)$$

此外，本文以舆情—行情融合特征训练 XGBoost[10] 方向判别模型，并以五折交叉验证的 AUC 评估其区分能力。需强调的是，上述指标用于说明风险信号具备可审计的历史验证过程，相关判别结果仅作为风险提示，而非可交易策略。

4 系统设计与实现

4.1 总体架构

为支撑上述方法的端到端运行，本文实现了分层的舆情风控研判系统。系统自下而上分为数据层、处理层、分析层、研判层、服务层与展示层，各层职责单一、逐级抽象，如图 2 所示。




图 2 系统六层总体架构

4.2 关键技术选型

各层技术选型在课程项目可控资源、可解释性与联调便利性之间取得平衡，如表 2 所示。

表 2 各层关键技术选型

层次	技术	选型说明
处理	Python + Pandas	适合课程规模的数据清洗、聚合与特征构建
持久	CSV + Parquet + DuckDB	兼顾原始追溯、列式分析与 SQL 复查
分析	词典 / FinBERT / LDA / XGBoost	覆盖可解释基线、主题分析与方向判别
研判	Prompt 模板	本地合成结构化简报，保证可复现
服务	FastAPI + Pydantic	接口清晰、轻量，便于联调与测试
展示	React + TypeScript + Recharts	适合组件化页面与异步数据展示

4.3 数据持久层设计

为兼顾原始数据可追溯、分析高效与复查便利，本文采用 CSV、Parquet 与 DuckDB 三者结合的持久方案：原始与统一事件以 CSV 保存以便追溯；处理产物以列式 Parquet 存储以加速分析层读取；同时导出 DuckDB 数据库以支持 SQL 方式的交互式复查。这一设计在课程项目规模下兼顾了效率与可复现性，且运行不依赖不可控的外部服务。

4.4 服务接口设计

处理与分析产物以只读方式经由服务层对外暴露，按元信息、核心数据与算法结果三类组织，共 13 个接口。主要接口及其用途如表 3 所示。只读设计确保演示阶段不会意外修改数据，降低了联调与答辩风险。

表 3 主要服务接口

接口	用途
/api/meta/health	健康检查与系统状态
/api/overview	个股总览：价格、情绪与风险信息
/api/linkage	价格—情绪—新闻量联动序列
/api/news/drilldown	预警日期与新闻钻取
/api/backtest	事件触发、前向收益与最大回撤
/api/meta/member-b-analysis	情绪、主题与风险算法结果
/api/meta/llm-brief	结构化研判简报

4.5 可视化展示

展示层采用 React + TypeScript + Recharts 构建，围绕研判流程组织为指挥总览、单股详情、舆情钻取与回测验证四个页面，分别对应宏观态势感知、个股画像分析、

风险证据钻取与历史有效性验证。各页面通过只读接口异步获取数据，并对空数据提供降级展示，保证演示稳健性。整体采用深色主题以适应金融监控场景的长时间使用，关键指标以卡片形式置顶，时序数据以联动图表呈现。以下分别介绍四个核心页面。

4.5.1 指挥总览页面

指挥总览是系统的入口页面，面向宏观态势感知。如图 3 所示，页面顶部以指标卡展示监测标的数、样本总数、活跃预警与谣言事件等全局统计；左侧为焦点个股的价格、情绪与热度三线联动图，用于识别舆情峰值与市场分歧；右侧“实时舆情热度榜”按热度与风险优先排序展示重点观察个股；下方进一步给出数据链路说明与风险事件快线，使评审能够快速把握系统的数据规模与整体运行状态。



图 3 指挥总览页面（核心区）。顶部为全局指标卡（监测标的数、样本总数、活跃预警、谣言事件），左侧为焦点个股价格—情绪—热度三线联动图，右侧为按热度与风险排序的实时舆情热度榜 Top 10；页面下方另设数据链路说明与风险事件快线（因版面所限未全部截取）

4.5.2 单股详情页面

单股详情页面面向个股画像分析，复用首页联动图风格并进一步细化。如图 4 所示，页面以个股的最新价格、情绪结论、舆情热度与疑似谣言占比为核心指标，辅以风险时间线、代表性舆情摘要、来源覆盖与风控占比，以及 AI 研判简报。其中风

险时间线将舆情事件与价格走势相关联，使风险的演化过程可追溯；代表性舆情摘要则直接展示触发风险判断的文本证据，体现了方法的可解释性。



图4 单股因子详情页面（核心区）。以个股最新价格、情绪结论、舆情热度与疑似谣言占比为核心指标，并以数据接入与算法结果汇总卡片展示覆盖规模、回测触发与风险评分；下方进一步给出单股联动图、代表性舆情摘要（文本证据）、来源覆盖与风控占比以及AI研判简报

4.5.3 舆情钻取页面

舆情钻取页面面向风险证据的细粒度核查。如图5所示，页面在指定预警日期下，将该日新闻热度拆解为核心新闻流，并标注每条文本的情绪倾向与置信度；右侧给出负面占比、关键负面驱动词、重点观察主题与数据覆盖情报。该页面使风控人员能够从聚合的风险信号逐层下钻到具体新闻与讨论，定位风险来源，是连接“风险结论”与“原始文本证据”的关键环节。

4.5.4 回测验证页面

回测验证页面面向风险信号的历史有效性验证，直接对应第3.6节的事件研究方法。如图6所示，页面以历史触发次数、平均前向收益、最大回撤与负收益命中率为核心指标，并以“平均收益轨迹”折线图展示信号触发后1至10日的价格走势，以“收益分布”图展示触发后收益的离散程度。需要说明的是，图6为单只标的



图5 舆情钻取页面（核心区）。在指定预警日期下将当日新闻热度拆解为核心新闻流，逐条标注情绪倾向与置信度；右侧给出负面占比、总信号数、关键负面驱动词、重点观察主题与数据覆盖情报，实现从聚合风险信号到具体文本证据的逐层下钻

(600519.SH) 在选定参数下的示例视图，故其触发次数等指标与第 5.5 节表 8 给出的全样本聚合结果（共触发 225 次）不同，二者口径分别为单股与全池，并不矛盾。页面底部明确标注所有计算均相对于指定交易日收盘时点，且仅用于历史验证研究、不构成投资建议，体现了方法的边界意识。

5 实验与结果分析

5.1 实验设置

5.1.1 数据集

实验数据来源于公开财经数据与离线提交包，避免将不可控的实时爬虫作为硬依赖。经统一治理后，得到 121,768 条标准文本事件，覆盖 1,000 只 A 股标的。各来源构成如表 4 所示，其中股吧讨论占比最高，反映了投资者社区是舆情的主要载体。

为更直观地呈现数据来源构成，将各文本来源的占比绘制为环形图，如图 7 所示。可见股吧讨论文本占据绝对主体（81.2%），新闻与公告分别占 13.8% 与 5.0%，这一分布也决定了本文方法需重点处理来自投资者社区的高噪声、口语化文本。




图 6 回测验证页面（以 600519.SH 单股示例）。核心指标为历史触发次数、平均前向收益、最大回撤与负收益命中率；下方”平均收益轨迹”展示触发后 1~10 日走势，”收益分布”展示触发后收益的离散程度。单股口径下的指标与表 8 的全样本聚合结果不同

表 4 多源数据构成

来源	说明	数量	占比
股吧讨论	投资者社区文本	98,893	81.2%
新闻	财经新闻报道	16,821	13.8%
公告	上市公司公告	6,054	5.0%
行情	实时行情样例	1,000	—
合计	统一文本事件	121,768	100%

注：占比按文本事件（不含行情序列）计算。




图7 多源文本数据来源构成

5.1.2 情绪标注评测子集

情绪分类的对比与敏感性实验需要带标签的评测数据。由于对 12 万余条全量文本进行人工标注成本过高，本文从统一文本事件中分层抽取构造评测子集，具体流程如下。第一，抽样：按来源（股吧讨论、新闻、公告）与情绪倾向分层随机抽取共 **2,000** 条文本，以保证类别与来源的代表性，避免单一来源主导评测。第二，弱标注初筛：以股吧帖子自带的“看涨/看跌”标记、新闻与公告中的规则化情绪线索为初始弱标签，对文本进行三分类（正面/中性/负面）预标注。第三，人工校验：由小组成员按统一标注规范对全部弱标签逐条复核与修正，标注规范明确了三类的判定边界（如：仅陈述事实而无明显倾向者归为中性；同一文本兼含正负面信息时以主导信息为准）。为评估标注一致性，随机抽取 300 条由两名标注者独立标注，计算得 Cohen's $\kappa = 0.78$ ，处于“高度一致”区间，表明标注结果可靠。最终评测子集的三类样本比例约为正面 32%、中性 41%、负面 27%。后续**所有情绪分类指标（表 5、图 8、图 10 及图 9）**均在该评测子集上以同一划分计算，确保三组方法可比。

5.1.3 方向判别的特征与标签

回测部分的方向判别模型用于在事件触发后对个股次日走势方向提供辅助提示，其特征与标签定义如下。特征向量由舆情侧与行情侧两组特征拼接而成：舆情侧包括个股日度融合情绪均值 s 、负面文本占比、文本量及其短期变化率、谣言关键词命中率、主题集中度等；行情侧包括滞后收益、换手率、成交量相对近期均值的偏离度、已实现波动率等。所有特征均严格使用截至事件锚定日 t_0 收盘前可观测的信息（见性质 3.1），不含任何未来信息。标签定义为个股在 t_0 之后次一交易日的收益方向，即 $y = \mathbb{I}[R^{(1)} > 0]$ ，构成二分类问题。模型以 XGBoost[10] 训练，并采用按时间排序的五折交叉验证以避免时序泄漏，报告 AUC 作为区分能力度量。

5.1.4 评价指标

本文从情绪分类、风险识别与历史验证三个层面进行评估。情绪分类层面采用准确率 (Accuracy)、宏平均 F1 (Macro-F1)；方向判别层面采用五折交叉验证 AUC；历史验证层面采用平均前向收益、最大回撤与事件触发次数。其中 F1 为精确率与召回率的调和平均，AUC 为受试者工作特征曲线下面积，二者均不受类别不平衡的简单影响，适合本文场景。

5.1.5 对比方法

为验证融合情绪方案的有效性，本文设置三组情绪计算方法进行对比：(1) 纯词典法，仅使用式 (2)；(2) 单一模型法，仅使用式 (3)，即在 FinBERT 可用时完全采用其输出；(3) 本文融合法，按式 (4) 融合，融合系数 $\alpha = 0.6$ 。三者在上一节构造的同一情绪标注评测子集、同一划分上进行评估，以保证可比性。需要说明的是，单一模型法在精度上通常最优，但其结果不具备词条级的可解释依据，且在模型服务不可用时无法运行；本文核心方案之所以选择融合而非纯模型，正是为了在风控场景下兼顾可解释性与鲁棒性，相关代价与收益将在第 5.2 节定量讨论。在全量 121,768 条文本事件上，系统默认以融合模式 ($\alpha = 0.6$) 运行；仅当模型通道不可用时，按算法 1 自动降级为纯词典模式。

5.2 情绪方法对比实验

三组方法在情绪分类评测子集上的结果如表 5 与图 8 所示。可以看出，纯词典法虽完全可解释，但受限于词表覆盖与语境建模能力，准确率与 Macro-F1 相对较低；单一模型法凭借上下文表示取得了最高精度，但其结果可解释性较弱，且强依赖模型服务。本文融合法在二者之间取得平衡：其准确率 (0.854) 与 Macro-F1 (0.846) 显著高于纯词典法（分别提升约 6.2 与 6.5 个百分点），并接近单一模型法（差距仅约 1.7 个百分点）。值得强调的是，融合法以这约 1.7 个百分点的精度让渡，换取了纯模型法所不具备的两项工程优势：一是词条级可追溯的可解释性，二是模型不可用时按式 (4) 自动降级为词典法的鲁棒性。在风控场景中，结论可被人工复核、系统可在服务波动时持续运行，往往比边际精度更为关键，因此该折中是合理且符合实际需求的。

表 5 给出了三组方法的总体准确率与 Macro-F1。为进一步揭示各方法在不同情绪类别上的表现差异，图 8 进一步分解了三类情绪（正面、中性、负面）各自的 F1 得分。可以看出，三组方法的性能差异主要来自**中性**与**负面**两类：纯词典法在中性

表 5 情绪方法对比结果

方法	准确率	Macro-F1	可解释性
纯词典法	0.792	0.781	强
单一模型法	0.871	0.863	弱
本文融合法	0.854	0.846	较强

文本上的 F1 明显偏低，反映了其难以区分”无明显倾向”与”弱倾向”文本的固有局限；而融合法借助模型通道，在中性与负面类上均较纯词典法有明显改善，逼近单一模型法。这一分解说明融合带来的增益主要体现在最易混淆、且对风控最为关键的负面类别上。




图 8 三种情绪方法在各类别上的 F1 分解

为更细致地考察融合法的错分模式，图 9 给出了本文融合法在评测子集上的归一化混淆矩阵。可见对角线占比普遍较高，主要的混淆发生在中性与负面之间——约 14% 的负面文本被误判为中性，这与金融文本中负面信息常以委婉、含蓄方式表达的特点一致，也为后续引入更强的语义模型指明了改进重点。

5.3 风险识别消融实验

为量化风险识别引擎中各模块的贡献，本文将表 1 的五条规则归并为三个功能模块进行消融：**情绪模块**（含负面情绪激增规则及方向判别中的情绪类特征）、**主题模块**（多粒度主题特征及由其衍生的热度类规则）、**背离模块**（情绪—价格背离规则）。之所以按模块而非逐条规则消融，是因为成交量异常与新闻热度异常等规则与其余特征高度耦合、单独移除意义有限，按功能模块划分更能反映各类信息源的边际贡献。本文以完整模型为基准，依次移除上述三个模块，观察方向判别 AUC 与回测前向收益的变化，结果如表 6 所示。




图9 本文融合法的归一化混淆矩阵（评测子集）

表6 风险识别消融实验

配置	AUC	平均前向收益	Δ AUC
完整模型	0.601	+0.42%	—
去除情绪规则	0.572	+0.27%	−0.029
去除主题特征	0.586	+0.34%	−0.015
去除背离规则	0.581	+0.31%	−0.020


注： Δ AUC 为相对完整模型的 AUC 变化，负值表示移除该模块后性能下降。

实验结果表明，移除任一模块均导致 AUC 与前向收益下降，说明情绪、主题与背离规则对风险识别均有正向贡献。其中，情绪规则的贡献最大（移除后 AUC 下降 0.029），印证了情绪信号在舆情风险识别中的核心地位；背离规则次之，说明情绪与价格的方向性分歧确实蕴含额外的风险信息；主题特征贡献相对较小，但仍为有效补充。

5.4 参数敏感性分析

5.4.1 融合系数 α

融合系数 α 控制模型法与词典法的权重。本文在 $\alpha \in \{0, 0.2, 0.4, 0.6, 0.8, 1.0\}$ 上考察情绪分类 Macro-F1 的变化，结果如图 10 所示。可以看出，随着 α 增大，F1 先上升后趋于平缓：当 α 由 0（纯词典）增至约 0.6 时，F1 提升明显；继续增大则提升有限。考虑到较大的 α 会削弱可解释性并加重对模型服务的依赖，本文取 $\alpha = 0.6$ 作为精度与可解释性的折中。

图 10 融合系数 α 对情绪分类性能的影响

5.4.2 风险阈值 θ

风险阈值 θ 决定风险预警的灵敏度。 θ 偏低会导致预警过于频繁、误报增多； θ 偏高则可能漏报。本文在不同 θ 取值下统计事件触发次数与平均前向收益，结果如表 7 所示。随着 θ 升高，触发次数迅速减少而单次事件的平均前向收益（绝对幅度）有所上升，说明较高阈值筛选出的事件后续波动更显著。综合预警覆盖与信号质量，本文将默认阈值设定在中等水平，以平衡灵敏度与误报率。

表 7 风险阈值 θ 的敏感性

阈值 θ	事件触发次数	平均前向收益
40	612	+0.21%
50	388	+0.33%
60	225	+0.42%
70	121	+0.55%

进一步地，不同阈值下风险等级的分布也随之变化。图 11 以堆叠柱状图展示了四个阈值下低、中、高风险标的的占比。可以看出，随着阈值升高，被判定为高风险的标的占比显著下降，而低风险占比相应上升，这与阈值升高使预警趋于保守的直觉一致。在默认阈值（ $\theta = 60$ ）下，三类风险等级的分布较为均衡，既保证了对高风险标的的覆盖，又避免了过度预警。

5.5 综合结果与讨论

综合上述实验，本文方法的整体表现如表 8 所示。在默认配置（ $\alpha = 0.6$ 、 $\theta = 60$ ）下，方向判别模型的五折交叉验证 AUC 约为 0.601，风险信号在样本期内共触发 225 次，事件窗口内平均前向收益约为 +0.42%，最大回撤约为 -0.68%。




图 11 不同阈值下风险等级分布

表 8 方法综合结果（默认配置）

指标	数值	说明
交叉验证 AUC	0.6014	方向判别模型的区分能力
事件触发次数	225	风险信号覆盖规模
平均前向收益	+0.42%	事件窗口内平均收益
最大回撤	-0.68%	触发后最大下行幅度

需要客观指出的是，AUC 约 0.60 的判别能力处于偏弱但合理的区间，这与金融时间序列的高噪声、弱可预测特性相一致。该结果表明，舆情—行情融合特征对次日方向具有一定但有限的辅助判别能力。本文方法的价值并不在于追求超额收益，而在于提供稳定、可解释、可审计的风险提示信号：相较纯黑箱模型，其每一条结论都可回溯到具体规则与文本证据，更适合风控场景中的人工复核。

为更直观地刻画风险信号触发后的价格走势，图 12 给出了全样本在信号触发日 t_0 之后 1 至 10 个交易日的平均前向收益轨迹及其 95% 置信区间。可以看出，触发后平均前向收益总体为小幅负向，并随窗口延长而缓慢走低，在第 5 至 7 日附近达到约 -0.7% 的低点，与表 8 的最大回撤量级一致；置信区间始终较宽且与零线高度重叠，再次印证了短期方向的弱可预测性——这与本文将信号定位为“风险提示”而非“交易策略”的立场相互印证。

进一步地，为缓解第 2.4 节所述简化事件研究框架的局限，本文以沪深 300 指数作为市场基准进行稳健性检验：将个股前向收益减去同期市场收益，得到近似的市场调整收益（abnormal return）。在默认配置下，触发后第 5 日的市场调整平均收益约为 -0.51%，较未调整的 -0.64% 有所收敛，但方向与显著性结论保持一致。这表明本文观察到的触发后弱负向走势并非完全由大盘系统性波动驱动，而是部分来自




图 12 风险信号触发后平均前向收益轨迹（阴影为 95% 置信区间）

个股层面的舆情冲击，从而为风险信号的有效性提供了更稳健的佐证。受课程项目数据条件限制，此处仅以单因子市场模型做近似校验，更严格的多因子调整留待未来工作。

6 讨论

6.1 方法有效性分析

本文实验从多个角度验证了所提方法的有效性。情绪方法对比表明，融合策略在精度与可解释性之间取得了良好平衡，其 Macro-F1 较纯词典法提升约 6.5 个百分点，同时保留了可降级与可解释的工程优势；消融实验表明，情绪、主题与背离规则模块对风险识别均有正向贡献，验证了多规则设计的合理性；参数敏感性分析则为融合系数与风险阈值的选取提供了量化依据。综合来看，方法的核心价值体现在三个方面：可解释性使风险结论可被人工复核，鲁棒性与可复现性使系统在模型服务不可用时仍能稳定运行，可验证性使方法有效性能够被客观评估。

6.2 局限性分析

本文方法仍存在若干局限。第一，方向判别 AUC 约为 0.60，区分能力有限，仅能作为辅助风险提示，这与金融短期方向的弱可预测性一致，也提示单纯依赖舆情特征预测短期走势的固有难度。第二，谣言识别目前以关键词规则与传播度阈值为主，对不含敏感词、以反讽或暗示方式表达的隐晦不实信息覆盖有限，存在一定漏报。第三，受课程项目资源约束，样本期与股票池规模仍可进一步扩展，且情绪计算中的领域模型在实际部署时对算力与服务稳定性有一定要求。第四，本文采用简化的事件研究框架，主体分析以原始前向收益近似刻画事件后走势；虽已补充以沪

深 300 为基准的单因子市场调整稳健性检验（见第 5.5 节），但尚未引入完整的多因子模型对正常收益进行严格调整，所得收益仍非严格意义上的风险调整异常收益。

6.3 改进方向

针对上述局限，未来可从以下方向改进：（1）扩展样本期与股票池，并引入流式采集以提升数据时效性；（2）以领域大语言模型替换本地情绪与研判模板，提升语义理解与简报质量；（3）引入基于深度学习的谣言检测模型，增强对隐晦不实信息的识别能力；（4）在回测中引入市场模型或多因子基准，度量经风险调整后的异常收益，提升结论的金融计量严谨性；（5）将单机批处理迁移到分布式计算框架，以支撑更大规模的数据与更复杂的特征工程。

7 结论与展望

7.1 全文总结

针对上市公司舆情来源分散、文本非结构化、风险识别滞后等问题，本文研究了面向多源中文舆情的上市公司风险研判方法，并实现了一套可复现、可解释、可验证的端到端辅助决策系统。本文的主要工作与结论如下：

第一，提出了多源异构舆情的统一治理与交易日锚定方法，将新闻、公告、股吧讨论与行情数据规整为统一文本事件表，并从理论上保证了风险计算与回测不引入未来信息泄漏，为后续分析提供了一致、可靠的数据基础。

第二，提出了词典基线与领域模型相融合、且支持自动降级的情绪计算方案。对比实验表明，该方案在情绪分类性能上显著优于纯词典法、接近单一模型法，所付出的代价仅为相对纯模型法约 1.7 个百分点的精度，换取的则是可解释性、可复现性与模型不可用时的鲁棒降级能力——这一折中在风控生产环境中具有现实意义。

第三，设计了基于多规则加权的可解释风险识别引擎，并通过消融实验量化了情绪、主题与背离规则各模块的贡献，验证了多规则设计的合理性。

第四，构建了基于事件研究的回测验证框架，并辅以参数敏感性分析。在 121,768 条统一文本事件、1,000 只 A 股标的的数据集上的实验表明，所提方法能够稳定地产生可解释、可审计的舆情风险辅助信号；其工程价值在于可复现与可解释，而非超额收益。

7.2 研究展望

本文方法可为上市公司舆情风险的辅助研判提供系统化的方法与工程参考。然而，受限于课程项目的资源与时间，本文在数据规模、模型能力与计量严谨性等方面仍有提升空间。未来研究可在以下方向继续深入：在数据层面，构建更大规模、更高质量、覆盖更长时间窗口的中文金融舆情数据集；在方法层面，引入大语言模型与深度谣言检测模型，提升语义理解与风险识别的精度；在验证层面，采用更严格的金融计量框架，度量经风险调整后的信号有效性。如何在保持可解释性的前提下进一步提升判别能力，并将方法扩展至更大规模、更高时效的实际场景，是后续值得持续探索的方向。

致谢：本文为《综合设计实验》课程项目成果。感谢课程指导教师的悉心指导，以及小组成员在数据、算法、系统与文档各环节的通力协作。本文所有研判结果仅用于课程展示，不构成任何投资建议。

数据可得性说明：本文实验数据来源于公开财经数据与离线提交数据包，经统一治理后用于课程研究；原始数据受第三方来源条款约束，整理后的统一文本事件表可应合理学术请求向作者获取。

作者贡献：四位作者分别主要负责数据治理与时点对齐、融合情绪与主题提取、可解释风险识别与回测验证、系统实现与可视化，并共同参与论文撰写与修订。

利益冲突：作者声明不存在利益冲突。

参考文献

- [1] 姜富伟, 孟令超, 唐国豪. 媒体文本情绪与股票回报预测 [J]. 经济学 (季刊), 2021, 21(4): 1323–1344.
- [2] 李合龙, 任昌松, 柳欣茹, 等. 金融市场文本情绪研究综述 [J]. 数据分析与知识发现, 2023, 7(12): 22–39.
- [3] LOUGHRAN T, MCDONALD B. When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks[J]. The Journal of Finance, 2011, 66(1): 35–65. DOI: 10.1111/j.1540-6261.2010.01625.x.
- [4] LOUGHRAN T, MCDONALD B. Textual analysis in accounting and finance: A survey[J]. Journal of Accounting Research, 2016, 54(4): 1187–1230. DOI: 10.1111/1475-679X.12123.
- [5] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics. Minneapolis: ACL, 2019: 4171–4186. DOI: 10.18653/v1/N19-1423.
- [6] ARACI D. FinBERT: Financial sentiment analysis with pre-trained language models[J]. arXiv preprint arXiv:1908.10063, 2019. DOI: 10.48550/arXiv.1908.10063.

- [7] BLEI D M, NG A Y, JORDAN M I. Latent Dirichlet allocation[J]. Journal of Machine Learning Research, 2003, 3: 993–1022.
- [8] MIHALCEA R, TARAU P. TextRank: Bringing order into text[C]//Proceedings of the 2004 Conference on Empirical Methods in Natural Language Processing. Barcelona: ACL, 2004: 404–411.
- [9] MACKINLAY A C. Event studies in economics and finance[J]. Journal of Economic Literature, 1997, 35(1): 13–39.
- [10] CHEN T, GUESTRIN C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2016: 785–794. DOI: 10.1145/2939672.2939785.
- [11] JIANG F, LEE J, MARTIN X, et al. Manager sentiment and stock returns[J]. Journal of Financial Economics, 2019, 132(1): 126–149. DOI: 10.1016/j.jfineco.2018.10.001.